

project

Yue Zhang et G  r  mi Bridonneau

Introduction

1 La transformation de Box-Cox

1. (r  fl  chir un nom/titre)

Si $\lambda = 0$, $h_\lambda(y) = \log y$, $\forall y > 0$.


On a (1) $h_\lambda(y) = x' \theta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma I_n)$.

– (mon id  e de solution)


La transformation \tilde{h}_λ est valable seulement pour $y > 0$. De plus pour tout $\lambda \neq 0$, la transformation \tilde{h}_λ est born  e et donc la transformation ne peut pas   tre gaussienne. Pour $\lambda = 0$ on n'a pas ce probl  me gr  ce    la surjectivit   du logarithme.

Si toutes les observations sont positives on peut quand m  me utiliser cette transformation car on perdra qu'une faible partie des donn  es normalement dans la queue    gauche de la r  partition. Par exemple si les donn  es ne suivent pas une loi normale mais une loi beta de param  tre $\alpha = 2, \beta = 2.2$ et qu'on utilise la transformation de Box et Cox avec $\lambda = 2$ on obtient:

```
lambda <- 2
a <- 2
b <- 2.2
plot({function (x) dbeta(x, a, b)})
```



```
plot({function (x) (dbeta(x, a, b)^lambda - 1)/lambda}, -0.2, 1.2)
```



On voit qu'on a aucune valeur négative et que donc la gaussianisation n'est pas parfaite mais cette transformation reste raisonnable.

2. Déterminer la fonction de vraisemblance

Supposons que pour $\beta = (\theta, \lambda, \sigma^2)'$ a $p \times 1$ vecteur de paramètres, on ait $h_\lambda(Y_i) = Z_i = x_i\theta + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, ε_i suivent une loi gaussien i.i.d. Donc par la définition de vraisemblance:

$$\begin{aligned}
 L(\lambda, \theta, \sigma^2; Y) &= \prod_{i=1}^n \frac{\partial F}{\partial Y_i} \\
 &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(h_\lambda(Y_i) - x_i\theta)^2}{2\sigma^2}\right) \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| \\
 &= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{\sum_{i=1}^n (h_\lambda(Y_i) - x_i\theta)^2}{2\sigma^2}\right) \prod_{i=1}^n \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| \\
 &= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^2}\right) \prod_{i=1}^n |Y_i^{\lambda-1}|
 \end{aligned} \tag{1}$$

Donc le terme $J(\lambda; Y) = \prod_{i=1}^n \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| = \prod_{i=1}^n |Y_i^{\lambda-1}|$, est la transformation de Jacobian de $h_\lambda(Y) - X\theta$ à Y .

3. Estimation du maximum de vraisemblance

A λ fixé, on souhaite déterminer l'estimateur du maximum de vraisemblance $\hat{\theta}(\lambda)$ et $\hat{\sigma}^2(\lambda)$. Donc tout d'abord, depuis l'équation 1 on calcule la log-vraisemblance.

$$\begin{aligned}\ell &= \log L(\lambda, \theta, \sigma^2; Y) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^2} + \sum_{i=1}^n \log |Y_i^{\lambda-1}| \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\|h_\lambda(Y) - X\theta\|^2}{2\sigma^2} + (\lambda - 1) \sum_{i=1}^n \log |Y_i|\end{aligned}\quad (2)$$

Ensuite, étant donné que la log-vraisemblance ℓ l'équation (2) est une transformation monotone de la vraisemblance L dans l'équation (1), on maximise la log-vraisemblance ℓ respectivement pour θ , σ^2 et λ , donc on obtient le premier ordre dérivation ci-dessous:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^4} = 0 \quad (3)$$

Donc on a $\hat{\sigma}^2 = \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{n} = \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n}$, avec $H = X(X'X)^{-1}X'$ et I_n matrice identité.

$$\begin{aligned}\frac{\partial \ell}{\partial \theta} &= -\frac{2(-X)'(h_\lambda(Y) - X\theta)}{2\sigma^2} \\ &= \frac{X'(h_\lambda(Y) - X\theta)}{\sigma^2} = 0\end{aligned}\quad (4)$$

Donc, $\hat{\theta} = (X'X)^{-1}X'h_\lambda(Y)$, par $X'h_\lambda(Y) = X'X\theta$.

Pour vérifier la formule avec $L_{max}(\lambda)$, on remplace nos env $\hat{\sigma}^2$ et $\hat{\theta}$ calculés dans les équations (3) et (4) dans la log-vraisemblance ℓ :

$$\begin{aligned}L_{max}(\lambda) &:= \ell = \log L(\lambda, \hat{\theta}(\lambda), \hat{\sigma}^2(\lambda)) \\ &= -\frac{n}{2} \log\left(\frac{\|h_\lambda(Y) - X\hat{\theta}\|^2}{n}\right) - \frac{\|h_\lambda(Y) - X\hat{\theta}\|^2 n}{2\|h_\lambda(Y) - X\hat{\theta}\|^2} + (\lambda - 1) \sum_{i=1}^n \log |Y_i| - \frac{n}{2} \log(2\pi) \\ &= -\frac{n}{2} \log(\hat{\sigma}^2(\lambda)) + (\lambda - 1) \sum_{i=1}^n \log |Y_i| - \frac{n}{2} - \frac{n}{2} \log(2\pi)\end{aligned}\quad (5)$$

Donc $a(n) = -\frac{n}{2} - \frac{n}{2} \log(2\pi)$ qui est bien une constante ne dépendant que de n . Maintenant on calcule l'env $\hat{\lambda}$:

$$\frac{\partial \ell}{\partial \lambda} = -\frac{2(h_\lambda(Y) - X\theta)' \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{2\sigma^2} + \sum_{i=1}^n \log |Y_i| = 0 \quad (6)$$

Et

$$\begin{aligned}
\frac{\partial L_{max}}{\partial \lambda} &= -\frac{n}{2} \frac{1}{\hat{\sigma}^2(\lambda)} \left| \frac{\partial \hat{\sigma}^2(\lambda)}{\partial \lambda} \right| + \sum_{i=1}^n \log |Y_i| \\
&= -\frac{n}{2} \frac{1}{\hat{\sigma}^2(\lambda)} \frac{2(h_\lambda(Y) - X\theta) \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{n} + \sum_{i=1}^n \log |Y_i| \\
&= -\frac{(h_\lambda(Y) - X\theta) \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{\hat{\sigma}^2} + \sum_{i=1}^n \log |Y_i| = 0
\end{aligned} \tag{7}$$

On peut bien vérifier que $\frac{\partial \ell}{\partial \lambda}$ et $\frac{\partial L_{max}}{\partial \lambda}$ sont égaux par calcul de l'équation maximum vraisemblance. Par l'équation (3), on sait que $\hat{\sigma}^2(\lambda) = \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n} = \frac{SCR(\lambda)}{n}$ avec $H = X(X'X)^{-1}X'$, est la somme de carrés résiduels de variance $h_\lambda(Y)$ divisée par n . Depuis l'équation (7), on peut continuer cette calcul en remplaçant $\hat{\sigma}^2$, et pour rappel $h_\lambda(Y) = \frac{Y^\lambda - 1}{\lambda}$:

$$\begin{aligned}
\frac{\partial L_{max}}{\partial \lambda} &= -\frac{n}{2} \frac{n}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} \frac{2h_\lambda(Y)'(I_n - H)}{n} \left(\frac{Y^\lambda \log Y}{\lambda} - \frac{Y^\lambda - 1}{\lambda^2} \right) + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} \left(\frac{Y^\lambda \log Y}{\lambda} - \frac{h_\lambda(Y)}{\lambda} \right) + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)\lambda^{-1}Y^\lambda \log Y}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} + n \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)\lambda} + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)u_\lambda(Y)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} + \frac{n}{\lambda} + \sum_{i=1}^n \log |Y_i|
\end{aligned} \tag{8}$$

avec $u_\lambda(Y) = \lambda^{-1}Y^\lambda \log Y$. Le numérateur dans l'équation (8) est la somme résiduelle des produits dans l'analyse de la covariance de $h_\lambda(Y)$ et $u_\lambda(Y)$. Maintenant on utilise la transformation normalisée afin de simplifier le résultat, on définit $z_\lambda(Y)$ ci-dessous:

$$\begin{aligned}
z_\lambda(Y) &= \frac{h_\lambda(Y)}{J(\lambda; Y)^{1/n}} \\
&= \frac{h_\lambda(Y)}{(\prod_{i=1}^n |Y_i|)^{\lambda-1/n}}
\end{aligned} \tag{9}$$

Donc $\hat{\sigma}^2$ devient $\hat{\sigma}^2(\lambda; z) = \frac{z_\lambda(Y)'(I_n - H)z_\lambda(Y)}{n} = \frac{SCR(\lambda; z)}{n}$, $SCR(\lambda; z)$ est la somme des carrés résiduelle de $z_\lambda(Y)$. De plus, $L_{max} = -\frac{n}{2} \log(\hat{\sigma}^2(\lambda; z)) + a(n)$, donc on propose de trouver $\hat{\lambda}$ qui maximise $L_{max}(\lambda)$, c'est à dire minimiser $\hat{\sigma}^2(\lambda; z)$. Donc on cherche l'emc (estimateur des moindres carrées)

$$\hat{\lambda} = \arg \min_{\lambda} SCR(\lambda; z) \tag{10}$$

Pour répondre que l'emv est-il gaussien à distance finie? Je sais pas comment expliquer mais par le théorème du cours, l'emv est asymptotiquement normale non? emmm je vais réfléchir. genre la distribution de $\sqrt{n}(\hat{\beta} - \beta)$, quand $n \rightarrow \infty$, elle converge en une loi normale.

$$\left[I_1(\beta)^{-1} \right]^{1/2} \sqrt{n}(\hat{\beta} - \beta) \rightarrow \mathcal{N}(0, I_{dp}) \quad (11)$$

$I_1(\beta)^{-1}$ est la matrice de l'information de Fisher, noté que $\hat{V} = I_1(\beta)^{-1}$ et I_{dp} est la matrice identité de la taille p .

4. Distribution asymptotique de l'emv

Estimer la variance de $\hat{\lambda}$

Soit $\hat{\beta}$ l'emv asymptotiquement normal,

$$\begin{aligned} \sqrt{n}(\hat{\beta} - \beta) &\rightarrow \mathcal{N}(0, I_1(\beta)^{-1}) \\ \hat{\beta} &\sim \mathcal{N}(\beta, I_1(\beta)^{-1}) \end{aligned} \quad (12)$$

Par la définition, la matrice de l'information de Fisher est écrite ci-dessous:

$$\begin{aligned} I_1(\beta) &= \mathbb{E}_\beta[\dot{\ell}\dot{\ell}'] \\ &= -\mathbb{E}_\beta[\ddot{\ell}] \end{aligned} \quad (13)$$

où $\ddot{\ell}$ est la matrice Hessian $\ddot{\ell} = \frac{\partial^2 \ell}{\partial \beta \partial \beta'}$ (pour rappelle que on a définit $\beta = (\theta, \lambda, \sigma^2)'$ a $p \times 1$ vecteur de paramètres). En particulier, on n'a pas forcément besoin d'estimer σ^2 simultanément avec θ et λ , donc pour simplifier les calculs, on décide de calculer la matrice Hessian de $L_{max}(\lambda)$. Dans l'équation (7), on a calculé

$$\frac{\partial L_{max}}{\partial \lambda} = -\frac{(h_\lambda(Y) - X\theta) \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{\hat{\sigma}^2} + \sum_{i=1}^n \log |Y_i|, \text{ et on obtient sans souci } \frac{\partial L_{max}}{\partial \theta} = \frac{X'(h_\lambda(Y) - X\theta)}{\hat{\sigma}^2}.$$

$$\begin{aligned} \ddot{\ell} &:= H(\beta) = \frac{\partial^2 L_{max}}{\partial \beta \partial \beta'} \\ &= -\hat{\sigma}^{-2} \begin{bmatrix} X'X & -X' \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right| \\ - \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right| X & \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|' \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right| + \left| \frac{\partial^2 h_\lambda(Y)}{\partial^2 \lambda} \right| (h_\lambda(Y) - X\theta) \end{bmatrix} \end{aligned} \quad (14)$$

$H(\beta)$ est bien une matrice définie négative. Etant donnée la distribution asymptotique normale de l'emv, on peut conclure que $\widehat{Var}(\hat{\beta}) = -[H(\hat{\beta})]^{-1}$, maintenant on calcul $\widehat{Var}(\hat{\lambda})$:

$$\widehat{Var}(\hat{\lambda}) = -H(\hat{\lambda})^{-1} \quad (15)$$

$$\text{où } H(\lambda) = \frac{\partial^2 L_{max}}{\partial^2 \lambda} = \frac{\left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|' \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right| + \left| \frac{\partial^2 h_\lambda(Y)}{\partial^2 \lambda} \right| h_\lambda(Y)' (I_n - H)}{-\hat{\sigma}^2}.$$

Intervalle de confiance

Etant donné que l'emv est asymptotiquement normalement distribué, donc on peut construire le test

$$T = \frac{\hat{\beta} - \beta}{\sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}} \sim \mathcal{N}(0, I_{dp}). \text{ Par définition, } P(q_{\alpha/2} < \frac{\hat{\beta} - \beta}{\sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}} < q_{1-\alpha/2}) = 1 - \alpha, \text{ donc on peut obtenir}$$

l'intervalle de confiance $[\hat{\beta} - q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}, \hat{\beta} + q_{\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}]$, où $q_{\alpha/2}$ et $q_{1-\alpha/2}$ sont quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ sous la loi normale. La distribution est symétrique par rapport à 0, donc l'IC estimateur β est également $[\hat{\beta} - q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}, \hat{\beta} + q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}]$.

L'intervalle de confiance de λ donc est $[\hat{\lambda} - q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\lambda})}{n}}, \hat{\lambda} + q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\lambda})}{n}}]$, où $\widehat{Var}(\hat{\lambda})$ est calculé dans l'équation (15).

Test de Wald

On définit $A = [0, 1, 0]$, $\beta = (\theta, \lambda, \sigma^2)'$, $\beta_0 = (\theta_0, \lambda_0, \sigma_0^2)'$

$H_0 : A(\beta - \beta_0) = 0$ contre $H_1 : A(\beta - \beta_0) \neq 0$

Sous H_0 :

$$T = [AVA']^{-1/2} A(\hat{\beta} - \beta_0) \rightarrow \mathcal{N}(0, I_{dp}) \quad (16)$$

En utilisant la propriété de la statistique de Wald, W est la carré de la norme de T et sa loi asymptotique sous H_0 est:

$$\begin{aligned} W &= (A\hat{\beta} - A\beta_0)(A\hat{V}A')^{-1}(A\hat{\beta} - A\beta_0)' \\ &= \frac{(\hat{\lambda} - \lambda_0)^2}{\widehat{Var}(\hat{\lambda})} \rightarrow \chi^2(1) \end{aligned} \quad (17)$$

où $\hat{V} = I_1(\hat{\beta})^{-1}$, et $W \geq 0$, la région de rejet est unilatère à droite de niveau asymptotique α pour une hypothèse bilatère est $\mathcal{R} = \left\{ W > q_{1-\alpha}^{\chi^2(1)} \right\}$ avec $P_{(H_0)}(\mathcal{R}) \rightarrow \alpha$.

5. Test du rapport vraisemblance

Par le théorème asymptotique du RV, sous H_0 :

$$TRV = -2\log(RV) \rightarrow \chi^2(1) \quad (18)$$

$TRV \geq 0$, la région de rejet $\mathcal{R} = \left\{ TRV > q_{1-\alpha}^{\chi^2(1)} \right\}$ du test de rapport de vraisemblances maximales est asymptotiquement de niveau α , $P_{(H_0)}(\mathcal{R}) \rightarrow \alpha$.

Par la définition de rapport de vraisemblance:

$$RV = \frac{L(\lambda_0; Y)}{L(\hat{\lambda}; Y)} \quad (19)$$

où L est la fonction de vraisemblance.

$$\begin{aligned} TRV &= -2 \log\left(\frac{L(\lambda_0; Y)}{L(\hat{\lambda}; Y)}\right) \\ &= -2(\log L(\lambda_0; Y) - \log L(\hat{\lambda}; Y)) \\ &= 2(L_{\max}(\hat{\lambda}; Y) - L_{\max}(\lambda; Y)) \\ &= 2\left(-\frac{n}{2} \log(\hat{\sigma}^2(\hat{\lambda})) + \frac{n}{2} \log(\hat{\sigma}^2(\lambda))\right) \\ &= n \log\left(\frac{\hat{\sigma}^2(\lambda)}{\hat{\sigma}^2(\hat{\lambda})}\right) \end{aligned} \quad (20)$$

2 Test de la méthode sur des données simulées

1. Modélisation la regression linéaire simple

Condition convergence

La condition de convergence indiquée dans la section 1 est bien vérifiée.

En effet on a que si $x_1, x_2, \dots \stackrel{i.i.d}{\sim} \mathcal{N}(0, 1)$,

$$\frac{X'X}{n} = \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} = \begin{bmatrix} 1 & \frac{1}{n} \sum_{i=1}^n x_i \\ \frac{1}{n} \sum_{i=1}^n x_i & \frac{1}{n} \sum_{i=1}^n x_i^2 \end{bmatrix} \quad (21)$$


On a de plus $\mathbb{E}[x_i^2] = \text{Var}(x_i) + \mathbb{E}[x_i]^2 = 1$. Ainsi d'après la loi des grands nombres on a $(X'X)/n$ qui converge vers la matrice identité de taille 2×2 qui est bien définie positive.


Estimer regression linéaire simple

Le modèle linéaire simple donc est $z_i = \mu + \theta x_i + \sigma \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, 1)$ i.i.d. Le plan d'expérience X est en taille $[n, p]$ i.e. $[50 \times 2]$, et $\hat{\theta} = (X'X)^{-1} X'Z$, $\hat{\sigma}^2 = \frac{1}{n-p} \|Z - X\hat{\theta}\|^2$.

Par la définition, $\frac{y_i^\lambda - 1}{\lambda} = h_\lambda(y_i) = z_i$, $y_i = (\lambda z_i + 1)^{1/\lambda}$.

Pour Z






En Traçant la profondeur ajustée en fonction de la profondeur observée, on peut observer que le modèle n'est pas bien ajustée, les points s'allongent autour de la première bissectrice, mais les ajustements parfois ne sont pas proches des valeurs observées, donc ce qui implique aussi les bruts résidus fortes.

Etude les résidus

Par la définition, les résidus $\hat{\varepsilon} = Z - X\hat{\theta}$. Et les résidus studentisés donc est $t_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}\sqrt{1-h_{i,i}}}$ où $h_{i,i}$ sont les éléments diagonaux de $H = X(X'X)^{-1}X'$.




On voit que les résidus bruts sont fortes parce que les valeurs observées ne sont pas elles-mêmes proches de 0 et estimées avec une petite précision. La plupart d'eux sont raisonnablement compris entre -2 et 2 sauf quatre points, en respectant la règle empirique d'appartenance de 95% des résidus à l'intervalle -2 et 2 .

2. Mise en oeuvre le calcul $\hat{\lambda}$

La variable Q est $(I_n - H)$, où I_n est la matrice identité de taille 50×50 , $H = X(X'X)^{-1}X'$. Le variable $sig2$ égale à $\frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n}$ qui est exactement $\hat{\sigma}^2$ où on a démontré dans l'équation (3). La fonction *Lmle* retourne le terme $-\frac{n}{2} \log(\hat{\sigma}^2)$.

-Lmax en fonction de lambda



On voit bien que la fonction $-L_{max}$ est une fonction quadratique convexe, au près de λ à 0.4, $-L_{max}$ atteint au minimum.

3. Calcul $\hat{\lambda}$ et $\widehat{Var}(\hat{\lambda})$

Etant donné que $Z = h_{\lambda}(Y)$ est la transformation de Y , par la définition donc $\lambda \neq 0$, pour la Méthodes Newton, on commence la itération à partir de 2. En utilisant la fonction optimisation *nlm*, on obtient la valeur estimée $\hat{\lambda}$ est *resopt\$estimate* = 0.3817253. Comme démontré dans l'équation (15), la variance de $\hat{\lambda}$ est l'inverse de hessian donc est 0.02948455. (Pour la minimisation $-L_{max}$, la matrice hessian est définie positive)

4. Tests hypothèses

Intervale de confiance

Comme on a montré dans le premier section, l'intervalle de confiance pour λ est $[\hat{\lambda} - q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\lambda})}{n}}, \hat{\lambda} + q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\lambda})}{n}}]$ au niveau asymptotiquement $1 - \alpha$. Ici on fixe α à 0.05, donc $q_{1-\alpha/2}$ est 1.959964 la quantile d'ordre $1 - \alpha/2$ sous loi normale, donc on obtien l'IC [0.3341304, 0.4293202].

Test de Wald

Das l'équation (17), on a montré $W = \frac{(\hat{\lambda} - \lambda_0)^2}{\widehat{Var}(\hat{\lambda})} \rightarrow \chi^2(1)$. Donc on veut tester $H_0 : \lambda = \lambda_0$, contre $H_1 : \lambda \neq \lambda_0$ par la statistique de Wald pour les quatres cas ci-dessous:

- 1) Par la définition de $h_\lambda(Y)$, quand $\lambda = 1$, les données Y ne nécessitent pas de transformation, donc dans le test $\lambda_0 = 1$. On a $W_{obs} > q_{1-\alpha}^{\chi^2}$ qui se trouve dans la région de rejet (unilatère à droite), et p-valeur $3.173886e - 04 < \alpha$, donc rejette H_0 et accèpte H_1 avec risque de premier espèce $\alpha = 5\%$.
- 2) De même raison, quand $\lambda = 2$, la transformation à appliquer aux observations est en racine carrée. Donc dans le test on veut $\lambda_0 = 2$. On a $W_{obs} > q_{1-\alpha}^{\chi^2}$ qui se trouve dans la région de rejet (unilatère à droite), et p-valeur $4.324529e - 21 < \alpha$, donc rejette H_0 et accèpte H_1 avec risque de premier espèce $\alpha = 5\%$.
- 3) Quand $\lambda_0 = 3$, on a $W_{obs} < q_{1-\alpha}^{\chi^2}$ qui ne se trouve pas dans la région de rejet, et p-valeur $6.341116e - 01 > \alpha$, donc rejette H_1 et accèpte H_0 avec risque de seconde espèce inconnue.
- 4) Quand $\lambda_0 = 0$, on a $W_{obs} > q_{1-\alpha}^{\chi^2}$ qui se trouve dans la région de rejet (unilatère à droite), et p-valeur $2.621087e - 02 < \alpha$, donc rejette H_0 et accèpte H_1 avec risque de premier espèce $\alpha = 5\%$.

Bien que les quatres valeurs ne se trouvent pas dans l'IC que l'on a calculé, mais parmi 1, 2 et 0, $\lambda = 0.3$ est le plus proche que l'IC et le test de Wald l'accèpte.

5. Test de rapport de vraisemblance

```
## [1] "lambda= 1"
## [1] "TRV: 11.6612671670031"
## [1] "p_value: 0.000638148590273245"
## [1] "conserve H_0? FALSE"
## [1] "lambda= 2"
## [1] "TRV: 65.294998963096"
## [1] "p_value: 6.44847820188885e-16"
## [1] "conserve H_0? FALSE"
## [1] "lambda= 0.3"
## [1] "TRV: 0.228985473731655"
## [1] "p_value: 0.632277106840376"
## [1] "conserve H_0? TRUE"
## [1] "lambda= 0.01"
## [1] "TRV: 4.87855396242026"
## [1] "p_value: 0.0271923906014042"
## [1] "conserve H_0? FALSE"
```

Par l'équation (20), TRV suit une loi $\chi^2(1)$, donc de même façon on calcule les TRV observés et les p-valeurs. De même façon d'analyser les résultats calculés, les conclusions sont mêmes que ce qui données par le test Wald dans question précédente.

6.

3 Cas pratique

```
##      y x1 x2 x3
## 1  674 -1 -1 -1
## 2 1414  0 -1 -1
## 3 3636  1 -1 -1
```

```
## 4 338 -1 0 -1
## 5 1022 0 0 -1
## 6 1568 1 0 -1


## [1] 27 4

## 'data.frame': 27 obs. of 4 variables:
## $ y : int 674 1414 3636 338 1022 1568 170 443 1140 370 ...
## $ x1: int -1 0 1 -1 0 1 -1 0 1 -1 ...
## $ x2: int -1 -1 -1 0 0 0 1 1 1 -1 ...
## $ x3: int -1 -1 -1 -1 -1 -1 -1 -1 -1 0 ...
```


1. Modèle regression linéaire multiple

On définit le modèle linéaire multiple (M1) $y = \mu + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \sigma \varepsilon$, $\varepsilon \sim \mathcal{N}(0, I_n)$ i.i.d.

```
##
## Call:
## lm(formula = y ~ ., data = df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -644.5 -279.1 -150.2  199.5 1268.0
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   861.37      93.94   9.169 3.83e-09 ***
## x1             660.00     115.06   5.736 7.66e-06 ***
## x2            -535.83     115.06  -4.657 0.000109 ***
## x3            -310.83     115.06  -2.702 0.012734 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 488.1 on 23 degrees of freedom
## Multiple R-squared:  0.7291, Adjusted R-squared:  0.6937
## F-statistic: 20.63 on 3 and 23 DF,  p-value: 1.028e-06
```




```
##      [,1]
## 1  861.3704
## x1  660.0000
## x2 -535.8333
## x3 -310.8333
```



```
##           [,1]
##      4521.37037
## longueur   13.20000
## amplitude -535.83333
## chargement -62.16667
```


2.



Conclusion