

project

Yue Zhang et G  r  mi Bridonneau

Introduction

1 La transformation de Box-Cox

1. (r  fl  chir un nom/titre)

Si $\lambda = 0$, $h_\lambda(y) = \log y$, $\forall y > 0$.


On a (1) $h_\lambda(y) = x' \theta + \varepsilon$, $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$.

– (mon id  e de solution)


La transformation \tilde{h}_λ est valable seulement pour $y > 0$. De plus pour tout $\lambda \neq 0$, la transformation \tilde{h}_λ est born  e et donc la transformation ne peut pas   tre gaussienne. Pour $\lambda = 0$ on n'a pas ce probl  me gr  ce    la surjectivit   du logarithme.

Si toutes les observations sont positives on peut quand m  me utiliser cette transformation car on perdra qu'une faible partie des donn  es normalement dans la queue    gauche de la r  partition. Par exemple si les donn  es ne suivent pas une loi normale mais une loi beta de param  tre $\alpha = 2, \beta = 2.2$ et qu'on utilise la transformation de Box et Cox avec $\lambda = 2$ on obtient:

```
lambda <- 2
a <- 2
b <- 2.2
plot({function (x) dbeta(x, a, b)})
```



```
plot({function (x) (dbeta(x, a, b)^lambda - 1)/lambda}, -0.2, 1.2)
```



On voit qu'on a aucune valeur négative et que donc la gaussianisation n'est pas parfaite mais cette transformation reste raisonnable.

2. Déterminer la fonction de vraisemblance

Supposons que pour $\beta = (\lambda, \theta, \sigma^2)'$ a $p \times 1$ vecteur de paramètres, on ait $h_\lambda(Y_i) = Z_i = x_i\theta + \varepsilon_i$, $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$, ε_i suivent une loi gaussien i.i.d. Donc par la définition de vraisemblance:

$$\begin{aligned}
L(\lambda, \theta, \sigma^2; Y) &= \prod_{i=1}^n \frac{\partial F}{\partial Y_i} \\
&= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(h_\lambda(Y_i) - x_i\theta)^2}{2\sigma^2}\right) \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| \\
&= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{\sum_{i=1}^n (h_\lambda(Y_i) - x_i\theta)^2}{2\sigma^2}\right) \prod_{i=1}^n \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| \\
&= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^2}\right) \prod_{i=1}^n |Y_i^{\lambda-1}|
\end{aligned} \tag{1}$$

Donc le terme $J(\lambda; Y) = \prod_{i=1}^n \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| = \prod_{i=1}^n |Y_i^{\lambda-1}|$, est la transformation de Jacobian de $h_\lambda(Y) - X\theta$ à Y .

3. Estimation du maximum de vraisemblance

A λ fixé, on peut déterminer l'emv par estimation du maximum de vraisemblance. Donc tout d'abord, depuis l'équation 1 on calcule le log-vraisemblance.

$$\begin{aligned}
\ell &= \log L(\lambda, \theta, \sigma^2; Y) \\
&= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^2} + \sum_{i=1}^n \log |Y_i^{\lambda-1}| \\
&= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\|h_\lambda(Y) - X\theta\|^2}{2\sigma^2} + (\lambda - 1) \sum_{i=1}^n \log |Y_i|
\end{aligned} \tag{2}$$

En suite, étant donnée que le log-vraisemblance ℓ l'équation 2 est une transformant monotone de vraisemblance L dans l'équation 1, on maximise log-vraisemblance ℓ en respectant θ , σ^2 et λ , donc on obtient le premier ordre dérivation ci-dessous:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^4} = 0 \tag{3}$$

Donc on a $\hat{\sigma}^2 = \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{n} = \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n}$, avec $H = X(X'X)^{-1}X'$ et I_n matrice identité.

$$\begin{aligned}
\frac{\partial \ell}{\partial \theta} &= -\frac{2(-X)'(h_\lambda(Y) - X\theta)}{2\sigma^2} \\
&= \frac{X'(h_\lambda(Y) - X\theta)}{\sigma^2} = 0
\end{aligned} \tag{4}$$

Donc, $\hat{\theta} = (X'X)^{-1}X'h_\lambda(Y)$, par $X'h_\lambda(Y) = X'X\theta$.

Pour vérifier $L_{max}(\lambda)$, on remplace notre l'emv $\hat{\sigma}^2$ et $\hat{\theta}$ calculé par l'équation 3 et 4 dans log-vraisemblance ℓ :

$$\begin{aligned}
L_{max}(\lambda) &:= \ell = \log L(\lambda, \hat{\theta}(\lambda), \hat{\sigma}^2(\lambda)) \\
&= -\frac{n}{2} \log\left(\frac{\|h_\lambda(Y) - X\theta\|^2}{n}\right) - \frac{\|h_\lambda(Y) - X\theta\|^2 n}{2\|h_\lambda(Y) - X\theta\|^2} + (\lambda - 1) \sum_{i=1}^n \log |Y_i| - \frac{n}{2} \log(2\pi) \\
&= -\frac{n}{2} \log(\hat{\sigma}^2(\lambda)) + (\lambda - 1) \sum_{i=1}^n \log |Y_i| - \frac{n}{2} - \frac{n}{2} \log(2\pi)
\end{aligned} \tag{5}$$

Donc $a(n) = -\frac{n}{2} - \frac{n}{2} \log(2\pi)$ est bien une constante ne dépendant que n . Maintenant on calcule l'emv $\hat{\lambda}$:

$$\frac{\partial \ell}{\partial \lambda} = -\frac{2(h_\lambda(Y) - X\theta) \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{2\sigma^2} + \sum_{i=1}^n \log |Y_i| = 0 \tag{6}$$

Et

$$\begin{aligned}
\frac{\partial L_{max}}{\partial \lambda} &= -\frac{n}{2} \frac{1}{\hat{\sigma}^2(\lambda)} \left| \frac{\partial \hat{\sigma}^2(\lambda)}{\partial \lambda} \right| + \sum_{i=1}^n \log |Y_i| \\
&= -\frac{n}{2} \frac{1}{\hat{\sigma}^2(\lambda)} \frac{2(h_\lambda(Y) - X\theta) \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{n} + \sum_{i=1}^n \log |Y_i| \\
&= -\frac{(h_\lambda(Y) - X\theta) \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{\hat{\sigma}^2} + \sum_{i=1}^n \log |Y_i| = 0
\end{aligned} \tag{7}$$

On peut bien vérifier que $\frac{\partial \ell}{\partial \lambda}$ et $\frac{\partial L_{max}}{\partial \lambda}$ sont égaux par calcul de l'équation maximum vraisemblance. Par l'équation 3, on sait que $\hat{\sigma}^2(\lambda) = \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n} = \frac{SCR(\lambda)}{n}$ avec $H = X(X'X)^{-1}X'$, est la somme de carrés résiduels de variance $h_\lambda(Y)$ divisée par n . Depuis l'équation 7, on peut continuer cette calcul en remplaçant $\hat{\sigma}^2$, et pour rappel $h_\lambda(Y) = \frac{Y^\lambda - 1}{\lambda}$:

$$\begin{aligned}
\frac{\partial L_{max}}{\partial \lambda} &= -\frac{n}{2} \frac{n}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} \frac{2h_\lambda(Y)'(I_n - H)}{n} \left(\frac{Y^\lambda \log Y}{\lambda} - \frac{Y^\lambda - 1}{\lambda^2} \right) + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} \left(\frac{Y^\lambda \log Y}{\lambda} - \frac{h_\lambda(Y)}{\lambda} \right) + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)\lambda^{-1}Y^\lambda \log Y}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} + n \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)\lambda} + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)u_\lambda(Y)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} + \frac{n}{\lambda} + \sum_{i=1}^n \log |Y_i|
\end{aligned} \tag{8}$$

avec $u_\lambda(Y) = \lambda^{-1}Y^\lambda \log Y$. Le numérateur dans l'équation 8 est la somme résiduelle des produits dans l'analyse de la covariance de $h_\lambda(Y)$ et $u_\lambda(Y)$. Maintenant on utilise la transformation normalisée afin de simplifier le résultat, on définit $z_\lambda(Y)$ ci-dessous:

$$\begin{aligned}
z_\lambda(Y) &= \frac{h_\lambda(Y)}{J(\lambda; Y)^{1/n}} \\
&= \frac{h_\lambda(Y)}{(\prod_{i=1}^n |Y_i|)^{\lambda-1/n}}
\end{aligned} \tag{9}$$

Donc $\hat{\sigma}^2$ devient $\hat{\sigma}^2(\lambda; z) = \frac{z_\lambda(Y)'(I_n - H)z_\lambda(Y)}{n} = \frac{SCR(\lambda; z)}{n}$, $SCR(\lambda; z)$ est la somme des carrées résiduelle de $z_\lambda(Y)$. De plus, $L_{max} = -\frac{n}{2} \log(\hat{\sigma}^2(\lambda; z)) + a(n)$, donc on propose de trouver $\hat{\lambda}$ qui maximise $L_{max}(\lambda)$, c'est à dire minimize $\hat{\sigma}^2(\lambda; z)$. Donc on cherche l'emc (estimateur des moindres carrées)

$$\hat{\lambda} = \arg \min_{\lambda} SCR(\lambda; z) \tag{10}$$

Pour répondre que l'emv est-il gaussien à distance finie? Je sais pas comment expliquer mais par le théorème du cours, l'emv est asymptotiquement normale non? emmm je vais réfléchir. genre la distribution de $\sqrt{n}(\hat{\beta} - \beta)$, quand $n \rightarrow \infty$, elle converge en une loi normale.

$$\left[\frac{V_n(\beta)^{-1}}{n} \right]^{1/2} \sqrt{n}(\hat{\beta} - \beta) \rightarrow \mathcal{N}(0, I_n) \tag{11}$$

$V_n(\beta)^{-1}$ est l'information de Fisher.

4. Distribution asymptotique de l'emv

Etant donné que l'emv est asymptotiquement normalement distribué, donc on peut construire le test


$$T = \frac{\hat{\beta} - \beta}{\sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}} \sim \mathcal{N}(0, 1). \text{ Par définition, } P(q_{\alpha/2} < \frac{\hat{\beta} - \beta}{\sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}} < q_{1-\alpha/2}) = 1 - \alpha, \text{ donc on peut obtenir}$$

l'intervalle de confiance $[\hat{\beta} - q_{1-\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}, \hat{\beta} - q_{\alpha/2} \sqrt{\frac{\widehat{Var}(\hat{\beta})}{n}}]$, où $q_{\alpha/2}$ et $q_{1-\alpha/2}$ sont quantiles d'ordre $\alpha/2$ et $1 - \alpha/2$ sous la loi normale.


5.

2 Test de la méthode sur des données simulées

1.



2.



3 Cas pratique

Conclusion