

# project

Yue Zhang et G  r  mi Bridonneau

## Introduction

### 1 La transformation de Box-Cox

#### 1. (r  fl  chir un nom/titre)

Si  $\lambda = 0$ ,  $h_\lambda(y) = \log y$ ,  $\forall y > 0$ .

On a (1)  $h_\lambda(y) = x' \theta + \varepsilon$ ,  $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ .

– (mon id  e de solution)

La transformation  $\tilde{h}_\lambda$  est valable seulement pour  $y > 0$ . De plus pour tout  $\lambda \neq 0$ , la transformation  $\tilde{h}_\lambda$  est born  e et donc la transformation ne peut pas   tre gaussienne. Pour  $\lambda = 0$  on n'a pas ce probl  me gr  ce    la surjectivit   du logarithme.

Si toutes les observations sont positives on peut quand m  me utiliser cette transformation car on perdra qu'une faible partie des donn  es normalement dans la queue    gauche de la r  partition. Par exemple si les donn  es ne suivent pas une loi normale mais une loi beta de param  tre  $\alpha = 2, \beta = 2.2$  et qu'on utilise la transformation de Box et Cox avec  $\lambda = 2$  on obtient:

On voit qu'on a aucune valeur n  gative et que donc la gaussianisation n'est pas parfaite mais cette transformation reste raisonnable.

#### 2. D  terminer la fonction de vraisemblance

Supposons que pour  $\beta = (\theta, \lambda, \sigma^2)'$  a  $p \times 1$  vecteur de param  tres, on ait  $h_\lambda(Y_i) = Z_i = x_i \theta + \varepsilon_i$ ,  $\varepsilon_i \sim \mathcal{N}(0, \sigma^2)$ ,  $\varepsilon_i$  suivent une loi gaussien i.i.d. Donc par la d  finition de vraisemblance:

$$\begin{aligned} L(\lambda, \theta, \sigma^2; Y) &= \prod_{i=1}^n \frac{\partial F}{\partial Y_i} \\ &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(h_\lambda(Y_i) - x_i \theta)^2}{2\sigma^2}\right) \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| \\ &= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{\sum_{i=1}^n (h_\lambda(Y_i) - x_i \theta)^2}{2\sigma^2}\right) \prod_{i=1}^n \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| \\ &= \left(\frac{1}{2\pi\sigma^2}\right)^{\frac{n}{2}} \exp\left(-\frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^2}\right) \prod_{i=1}^n |Y_i^{\lambda-1}| \end{aligned} \tag{1}$$

Donc le terme  $J(\lambda; Y) = \prod_{i=1}^n \left| \frac{\partial h_\lambda(Y_i)}{\partial Y_i} \right| = \prod_{i=1}^n |Y_i^{\lambda-1}|$ , est la transformation de Jacobien de  $h_\lambda(Y) - X\theta$      $Y$ .

### 3. Estimation du maximum de vraisemblance

A  $\lambda$  fixé, on souhaite déterminer l'estimateur du maximum de vraisemblance  $\hat{\theta}(\lambda)$  et  $\hat{\sigma}^2(\lambda)$ . Donc tout d'abord, depuis l'équation 1 on calcule la log-vraisemblance.

$$\begin{aligned}\ell &= \log L(\lambda, \theta, \sigma^2; Y) \\ &= -\frac{n}{2} \log(2\pi\sigma^2) - \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^2} + \sum_{i=1}^n \log |Y_i^{\lambda-1}| \\ &= -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{\|h_\lambda(Y) - X\theta\|^2}{2\sigma^2} + (\lambda - 1) \sum_{i=1}^n \log |Y_i|\end{aligned}\quad (2)$$

Ensuite, étant donné que la log-vraisemblance  $\ell$  l'équation (2) est une transformation monotone de la vraisemblance  $L$  dans l'équation (1), on maximise la log-vraisemblance  $\ell$  respectivement pour  $\theta$ ,  $\sigma^2$  et  $\lambda$ , donc on obtient le premier ordre dérivation ci-dessous:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2} \frac{1}{\sigma^2} + \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{2\sigma^4} = 0 \quad (3)$$

Donc on a  $\hat{\sigma}^2 = \frac{(h_\lambda(Y) - X\theta)'(h_\lambda(Y) - X\theta)}{n} = \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n}$ , avec  $H = X(X'X)^{-1}X'$  et  $I_n$  matrice identité.

$$\begin{aligned}\frac{\partial \ell}{\partial \theta} &= -\frac{2(-X)'(h_\lambda(Y) - X\theta)}{2\sigma^2} \\ &= \frac{X'(h_\lambda(Y) - X\theta)}{\sigma^2} = 0\end{aligned}\quad (4)$$

Donc,  $\hat{\theta} = (X'X)^{-1}X'h_\lambda(Y)$ , par  $X'h_\lambda(Y) = X'X\theta$ .

Pour vérifier la formule avec  $L_{max}(\lambda)$ , on remplace nos env  $\hat{\sigma}^2$  et  $\hat{\theta}$  calculés dans les équations (3) et (4) dans la log-vraisemblance  $\ell$ :

$$\begin{aligned}L_{max}(\lambda) &:= \ell = \log L(\lambda, \hat{\theta}(\lambda), \hat{\sigma}^2(\lambda)) \\ &= -\frac{n}{2} \log\left(\frac{\|h_\lambda(Y) - X\hat{\theta}\|^2}{n}\right) - \frac{\|h_\lambda(Y) - X\hat{\theta}\|^2 n}{2\|h_\lambda(Y) - X\hat{\theta}\|^2} + (\lambda - 1) \sum_{i=1}^n \log |Y_i| - \frac{n}{2} \log(2\pi) \\ &= -\frac{n}{2} \log(\hat{\sigma}^2(\lambda)) + (\lambda - 1) \sum_{i=1}^n \log |Y_i| - \frac{n}{2} - \frac{n}{2} \log(2\pi)\end{aligned}\quad (5)$$

Donc  $a(n) = -\frac{n}{2} - \frac{n}{2} \log(2\pi)$  qui est bien une constante ne dépendant que de  $n$ . Maintenant on calcule l'env  $\hat{\lambda}$ :

$$\frac{\partial \ell}{\partial \lambda} = -\frac{2(h_\lambda(Y) - X\theta)' \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right|}{2\sigma^2} + \sum_{i=1}^n \log |Y_i| = 0 \quad (6)$$

Et

$$\begin{aligned}
\frac{\partial L_{max}}{\partial \lambda} &= -\frac{n}{2} \frac{1}{\hat{\sigma}^2(\lambda)} \left| \frac{\partial \hat{\sigma}^2(\lambda)}{\partial \lambda} \right| + \sum_{i=1}^n \log |Y_i| \\
&= -\frac{n}{2} \frac{1}{\hat{\sigma}^2(\lambda)} \frac{2(h_\lambda(Y) - X\theta)}{n} \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right| + \sum_{i=1}^n \log |Y_i| \\
&= -\frac{(h_\lambda(Y) - X\theta)}{\hat{\sigma}^2} \left| \frac{\partial h_\lambda(Y)}{\partial \lambda} \right| + \sum_{i=1}^n \log |Y_i| = 0
\end{aligned} \tag{7}$$

On peut bien vérifier que  $\frac{\partial \ell}{\partial \lambda}$  et  $\frac{\partial L_{max}}{\partial \lambda}$  sont égaux par calcul de l'équation maximum vraisemblance. Par l'équation (3), on sait que  $\hat{\sigma}^2(\lambda) = \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{n} = \frac{SCR(\lambda)}{n}$  avec  $H = X(X'X)^{-1}X'$ , est la somme de carrés résiduels de variance  $h_\lambda(Y)$  divisée par  $n$ . Depuis l'équation (7), on peut continuer cette calcul en remplaçant  $\hat{\sigma}^2$ , et pour rappel  $h_\lambda(Y) = \frac{Y^\lambda - 1}{\lambda}$ :

$$\begin{aligned}
\frac{\partial L_{max}}{\partial \lambda} &= -\frac{n}{2} \frac{n}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} \frac{2h_\lambda(Y)'(I_n - H)}{n} \left( \frac{Y^\lambda \log Y}{\lambda} - \frac{Y^\lambda - 1}{\lambda^2} \right) + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} \left( \frac{Y^\lambda \log Y}{\lambda} - \frac{h_\lambda(Y)}{\lambda} \right) + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)\lambda^{-1}Y^\lambda \log Y}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} + n \frac{h_\lambda(Y)'(I_n - H)h_\lambda(Y)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)\lambda} + \sum_{i=1}^n \log |Y_i| \\
&= -n \frac{h_\lambda(Y)'(I_n - H)u_\lambda(Y)}{h_\lambda(Y)'(I_n - H)h_\lambda(Y)} + \frac{n}{\lambda} + \sum_{i=1}^n \log |Y_i|
\end{aligned} \tag{8}$$

avec  $u_\lambda(Y) = \lambda^{-1}Y^\lambda \log Y$ . Le numérateur dans l'équation (8) est la somme résiduelle des produits dans l'analyse de la covariance de  $h_\lambda(Y)$  et  $u_\lambda(Y)$ . Maintenant on utilise la transformation normalisée afin de simplifier le résultat, on définit  $z_\lambda(Y)$  ci-dessous:

$$\begin{aligned}
z_\lambda(Y) &= \frac{h_\lambda(Y)}{J(\lambda; Y)^{1/n}} \\
&= \frac{h_\lambda(Y)}{(\prod_{i=1}^n |Y_i|)^{\lambda-1/n}}
\end{aligned} \tag{9}$$

Donc  $\hat{\sigma}^2$  devient  $\hat{\sigma}^2(\lambda; z) = \frac{z_\lambda(Y)'(I_n - H)z_\lambda(Y)}{n} = \frac{SCR(\lambda; z)}{n}$ ,  $SCR(\lambda; z)$  est la somme des carrées résiduelle de  $z_\lambda(Y)$ . De plus,  $L_{max} = -\frac{n}{2} \log(\hat{\sigma}^2(\lambda; z)) + a(n)$ , donc on propose de trouver  $\hat{\lambda}$  qui maximise  $L_{max}(\lambda)$ , c'est à dire minimize  $\hat{\sigma}^2(\lambda; z)$ . Donc on cherche l'emc (estimateur des moindres carrées)

$$\hat{\lambda} = \arg \min_{\lambda} SCR(\lambda; z) \tag{10}$$

Par le théorème du cours, l'emv est asymptotiquement normale, donc la distribution de  $\sqrt{n}(\hat{\beta} - \beta)$ , quand  $n \rightarrow \infty$ , elle converge en une loi normale.

$$\widehat{V}^{-1/2}\sqrt{n}(\widehat{\beta} - \beta) \rightarrow \mathcal{N}(0, I_{dp}) \quad (11)$$

$I_1(\beta)^{-1}$  est la matrice de l'information de Fisher, noté que  $\widehat{V} = I_1(\beta)^{-1}$  et  $I_{dp}$  est la matrice identité de la taille  $p$ . Quand  $n \geq 30$ , par le théorème TCL,  $\widehat{\beta}$  tends à gaussien, donc à distance finie la distribution de  $\widehat{\beta}$  approche à loi gaussienne.

#### 4. Distribution asymptotique de l'emv

##### Estimer la variance de $\widehat{\lambda}$

Par la propriété de l'emv, quand  $\widehat{\beta}$  tend à devenir gaussien et on peut prendre pour loi approchée à distance finie la loi asymptotique

$$\begin{aligned} \widehat{V}^{-1/2}(\widehat{\beta} - \beta) &\overset{appr}{\sim} \mathcal{N}(0, I_{dp}) \\ \widehat{\beta} &\overset{appr}{\sim} \mathcal{N}(\beta, I_1(\beta)^{-1}) \end{aligned} \quad (12)$$

Par la définition, la matrice de l'information de Fisher est écrite ci-dessous:

$$\begin{aligned} I_1(\beta) &= \mathbb{E}_{\beta}[\dot{\ell}\dot{\ell}'] \\ &= -\mathbb{E}_{\beta}[\ddot{\ell}] \end{aligned} \quad (13)$$

où  $\ddot{\ell}$  est la matrice Hessian  $\ddot{\ell} = \frac{\partial^2 \ell}{\partial \beta \partial \beta'}$  (pour rappelle que on a définit  $\beta = (\theta, \lambda, \sigma^2)'$  a  $p \times 1$  vecteur de paramètres). En particulier, on n'a pas forcément besoin d'estimer  $\sigma^2$  simultanément avec  $\theta$  et  $\lambda$ , donc pour simplifier les calculs, on décide de calculer la matrice Hessian de  $L_{max}(\lambda)$ . Dans l'équation (7), on a calculé

$$\frac{\partial L_{max}}{\partial \lambda} = -\frac{(h_{\lambda}(Y) - X\theta) \left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right|}{\widehat{\sigma}^2} + \sum_{i=1}^n \log |Y_i|, \text{ et on obtient sans souci } \frac{\partial L_{max}}{\partial \theta} = \frac{X'(h_{\lambda}(Y) - X\theta)}{\widehat{\sigma}^2}.$$

$$\begin{aligned} \ddot{\ell} &:= H(\beta) = \frac{\partial^2 L_{max}}{\partial \beta \partial \beta'} \\ &= -\widehat{\sigma}^{-2} \begin{bmatrix} X'X & -X' \left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right| \\ - \left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right| X & \left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right|' \left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right| + \left| \frac{\partial^2 h_{\lambda}(Y)}{\partial^2 \lambda} \right| (h_{\lambda}(Y) - X\theta) \end{bmatrix} \end{aligned} \quad (14)$$

$H(\beta)$  est bien une matrice définie négative. Etant donnée la distribution asymptotique normale de l'emv, on peut conclure que  $\widehat{Var}(\widehat{\beta}) = -[H(\widehat{\beta})]^{-1}$ , maintenant on calcul  $\widehat{Var}(\widehat{\lambda})$ :

$$\widehat{Var}(\widehat{\lambda}) = -H(\widehat{\lambda})^{-1} \quad (15)$$

$$\text{où } H(\lambda) = \frac{\partial^2 L_{max}}{\partial^2 \lambda} = \frac{\left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right|' \left| \frac{\partial h_{\lambda}(Y)}{\partial \lambda} \right| + \left| \frac{\partial^2 h_{\lambda}(Y)}{\partial^2 \lambda} \right| h_{\lambda}(Y)' (I_n - H)}{-\widehat{\sigma}^2}.$$

### Intervalle de confiance

Soit l'emv est asymptotiquement normalement distribué, par la propriété dans l'équation (12), donc on peut construire le test  $T = \frac{\hat{\beta} - \beta}{\sqrt{\widehat{Var}(\hat{\beta})}} \sim \mathcal{N}(0, I_{dp})$ . Par définition,  $P(q_{\alpha/2} < \frac{\hat{\beta} - \beta}{\sqrt{\widehat{Var}(\hat{\beta})}} < q_{1-\alpha/2}) = 1 - \alpha$ , donc

on peut obtenir l'intervalle de confiance  $[\hat{\beta} - q_{1-\alpha/2}\sqrt{\widehat{Var}(\hat{\beta})}, \hat{\beta} + q_{1-\alpha/2}\sqrt{\widehat{Var}(\hat{\beta})}]$ , où  $q_{\alpha/2}$  et  $q_{1-\alpha/2}$  sont quantiles d'ordre  $\alpha/2$  et  $1 - \alpha/2$  sous la loi normale  $\mathcal{N}(0, 1)$ . La distribution est symétrique par rapport à 0, donc l'IC estimateur  $\beta$  est également  $[\hat{\beta} - q_{1-\alpha/2}\sqrt{\widehat{Var}(\hat{\beta})}, \hat{\beta} + q_{1-\alpha/2}\sqrt{\widehat{Var}(\hat{\beta})}]$ .

L'intervalle de confiance de  $\lambda$  donc est  $[\hat{\lambda} - q_{1-\alpha/2}\sqrt{\widehat{Var}(\hat{\lambda})}, \hat{\lambda} + q_{1-\alpha/2}\sqrt{\widehat{Var}(\hat{\lambda})}]$ , où  $\widehat{Var}(\hat{\lambda})$  est calculé dans l'équation (15).

### Test de Wald

On définit  $A = [0, 1, 0]$ ,  $\beta = (\theta, \lambda, \sigma^2)'$ ,  $\beta_0 = (\theta_0, \lambda_0, \sigma_0^2)'$

$H_0 : A(\beta - \beta_0) = 0$  contre  $H_1 : A(\beta - \beta_0) \neq 0$

Sous  $H_0$ :

$$T = [AVA']^{-1/2}A(\hat{\beta} - \beta_0) \rightarrow \mathcal{N}(0, I_{dp}) \quad (16)$$

En utilisant la propriété de la statistique de Wald,  $W$  est la carré de la norme de  $T$  et sa loi asymptotique sous  $H_0$  est:

$$\begin{aligned} W &= (A\hat{\beta} - A\beta_0)(A\hat{V}A')^{-1}(A\hat{\beta} - A\beta_0)' \\ &= \frac{(\hat{\lambda} - \lambda_0)^2}{\widehat{Var}(\hat{\lambda})} \rightarrow \chi^2(1) \end{aligned} \quad (17)$$

où  $\hat{V} = I_1(\hat{\beta})^{-1}$ , et  $W \geq 0$ , la région de rejet est unilatère à droite de niveau asymptotique  $\alpha$  pour une hypothèse bilatère est  $\mathcal{R} = \left\{ W > q_{1-\alpha}^{\chi^2(1)} \right\}$  avec  $P_{(H_0)}(\mathcal{R}) \rightarrow \alpha$ .

## 5. Test du rapport vraisemblance

Par le théorème asymptotique du RV, sous  $H_0$ :

$$TRV = -2\log(RV) \rightarrow \chi^2(1) \quad (18)$$

$TRV \geq 0$ , la région de rejet  $\mathcal{R} = \left\{ TRV > q_{1-\alpha}^{\chi^2(1)} \right\}$  du test de rapport de vraisemblances maximales est asymptotiquement de niveau  $\alpha$ ,  $P_{(H_0)}(\mathcal{R}) \rightarrow \alpha$ .

Par la définition de rapport de vraisemblance:

$$RV = \frac{L(\lambda_0; Y)}{L(\hat{\lambda}; Y)} \quad (19)$$

où  $L$  est la fonction de vraisemblance.

$$\begin{aligned}
TRV &= -2 \log\left(\frac{L(\lambda_0; Y)}{L(\hat{\lambda}; Y)}\right) \\
&= -2(\log L(\lambda_0; Y) - \log L(\hat{\lambda}; Y)) \\
&= 2(L_{max}(\hat{\lambda}; Y) - L_{max}(\lambda; Y)) \\
&= 2\left(-\frac{n}{2} \log(\hat{\sigma}^2(\hat{\lambda})) + \frac{n}{2} \log(\hat{\sigma}^2(\lambda))\right) \\
&= n \log\left(\frac{\hat{\sigma}^2(\lambda)}{\hat{\sigma}^2(\hat{\lambda})}\right)
\end{aligned} \tag{20}$$

## 2 Test de la méthode sur des données simulées

### 1. Modélisation la regression linéaire simple

#### Condition convergence

La condition de convergence indiquée dans la section 1 est bien vérifiée.

En effet on a que si  $x_1, x_2, \dots \stackrel{i.i.d}{\sim} \mathcal{N}(0, 1)$ ,

$$\frac{X'X}{n} = \frac{1}{n} \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \end{bmatrix} \begin{bmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{bmatrix} = \begin{bmatrix} 1 & \frac{1}{n} \sum_{i=1}^n x_i \\ \frac{1}{n} \sum_{i=1}^n x_i & \frac{1}{n} \sum_{i=1}^n x_i^2 \end{bmatrix} \tag{21}$$


On a de plus  $\mathbb{E}[x_i^2] = \text{Var}(x_i) + \mathbb{E}[x_i]^2 = 1$ . Ainsi d'après la loi des grands nombres on a  $(X'X)/n$  qui converge vers la matrice identité de taille  $2 \times 2$  qui est bien définie positive.

#### Estimer regression linéaire simple


Le modèle linéaire simple donc est  $z_i = \mu + \theta x_i + \sigma \varepsilon_i$ ,  $\varepsilon_i \sim \mathcal{N}(0, 1)$  i.i.d. Le plan d'expérience  $X$  est en taille  $[n, p]$  i.e.  $[50 \times 2]$ , et  $\hat{\theta} = (X'X)^{-1} X'Z$ ,  $\hat{\sigma}^2 = \frac{1}{n-p} \|Z - X\hat{\theta}\|^2$ .

Par la définition,  $\frac{y_i^\lambda - 1}{\lambda} = h_\lambda(y_i) = z_i$ ,  $y_i = (\lambda z_i + 1)^{1/\lambda}$ .

### Pour Z




### Pour Y



En Traçant la profondeur ajustée en fonction de la profondeur observée, on peut observer que le modèle n'est pas bien ajustée, les points s'allongent autour de la première bissectrice, mais les ajustements parfois ne sont pas proches des valeurs observées, donc ce qui implique aussi les bruts résidus fortes.

## Etude les résidus

Par la définition, les résidus  $\hat{\varepsilon} = Z - X\hat{\theta}$ . Et les résidus studentisés donc est  $t_i = \frac{\hat{\varepsilon}_i}{\hat{\sigma}\sqrt{1-h_{i,i}}}$  où  $h_{i,i}$  sont les éléments diagonaux de  $H = X(X'X)^{-1}X'$ .




On voit que les résidus bruts sont fortes parce que les valeurs observées ne sont pas elles-mêmes proches de 0 et estimées avec une petite précision. La plupart d'eux sont raisonnablement compris entre  $-2$  et  $2$  sauf quatre points, en respectant la règle empirique d'appartenance de 95% des résidus à l'intervalle  $-2$  et  $2$ .

## 2. Mise en oeuvre le calcul $\hat{\lambda}$

La variable  $Q$  est  $(I_n - H)$ , où  $I_n$  est la matrice identité de taille  $50 \times 50$ ,  $H = X(X'X)^{-1}X'$ . Le variable  $sig2$  égale à  $\frac{h_{\lambda}(Y)'(I_n - H)h_{\lambda}(Y)}{n}$  qui est exactement  $\hat{\sigma}^2$  où on a démontré dans l'équation (3). La fonction *Lmle* retourne le terme  $-\frac{n}{2} \log(\hat{\sigma}^2)$ .



## -Lmax en fonction de lambda



On voit bien que la fonction  $-L_{max}$  est une fonction quadratique convexe, au près de  $\lambda$  à 0.4,  $-L_{max}$  atteint au minimum.

### 3. Calcul $\hat{\lambda}$ et $\widehat{Var}(\hat{\lambda})$

Etant donné que  $Z = h_{\lambda}(Y)$  est la transformation de  $Y$ , par la définition donc  $\lambda \neq 0$ , pour la Méthodes Newton, on commence la itération à partir de 2. En utilisant la fonction optimisation *nlm*, on obtient la valeur estimée  $\hat{\lambda}$  est `resopt$estimate` = 0.3817253. Comme démontré dans l'équation (15), la variance de  $\hat{\lambda}$  est l'inverse de hessian donc est 0.02948455. (Pour la minimisation  $-L_{max}$ , la matrice hessian est définie positive)

## 4. Tests hypothèses

### Intervale de confiance

Comme on a montré dans le premier section, l'intervalle de confiance pour  $\lambda$  est  $[\hat{\lambda} - q_{1-\alpha/2} \sqrt{\widehat{Var}(\hat{\lambda})}, \hat{\lambda} + q_{1-\alpha/2} \sqrt{\widehat{Var}(\hat{\lambda})}]$  au niveau asymptotiquement  $1 - \alpha$ . Ici on fixe  $\alpha$  à 0.05, donc  $q_{1-\alpha/2}$  est 1.959964 la quantile d'ordre  $1 - \alpha/2$  sous loi normale, donc on obtien l'IC [0.04517863, 0.718272].

### Test de Wald

Das l'équation (17), on a montré  $W = \frac{(\hat{\lambda} - \lambda_0)^2}{\widehat{Var}(\hat{\lambda})} \rightarrow \chi^2(1)$ . Donc on veut tester  $H_0 : \lambda = \lambda_0$ , contre  $H_1 : \lambda \neq \lambda_0$  par la statistique de Wald pour les quatres cas ci-dessous:

- 1) Par la définition de  $h_{\lambda}(Y)$ , quand  $\lambda = 1$ , les données  $Y$  ne nécessitent pas de transformation, donc dans le test  $\lambda_0 = 1$ . On a  $W_{obs} < q_{1-\alpha}^2$  qui ne se trouve pas dans la région de rejet (unilatère à droite), et p-valeur 0.4909476286  $> \alpha$ , donc rejette  $H_1$  et accèpte  $H_0$  avec risque de seconde espèce inconnue.

- 2) De même raison, quand  $\lambda = 0.5$ , la transformation à appliquer aux observations est en racine carrée. Donc dans le test on veut  $\lambda_0 = 0.5$ . On a  $W_{obs} < q_{1-\alpha}^{\chi^2}$  qui se trouve dans la région de rejet (unilatère à droite), et p-valeur  $4.324529e - 21 > \alpha$ , donc rejette  $H_0$  et accepte  $H_1$  avec risque de premier espèce  $\alpha = 5\%$ .
- 3) Quand  $\lambda_0 = 3$ , on a  $W_{obs} < q_{1-\alpha}^{\chi^2}$  qui ne se trouve pas dans la région de rejet, et p-valeur  $6.341116e - 01 > \alpha$ , donc rejette  $H_1$  et accepte  $H_0$  avec risque de seconde espèce inconnue.
- 4) Quand  $\lambda_0 = 0$ , on a  $W_{obs} > q_{1-\alpha}^{\chi^2}$  qui se trouve dans la région de rejet (unilatère à droite), et p-valeur  $2.621087e - 02 < \alpha$ , donc rejette  $H_0$  et accepte  $H_1$  avec risque de premier espèce  $\alpha = 5\%$ .

Bien que les quatres valeurs ne se trouvent pas dans l'IC que l'on a calculé, mais parmi 1, 2 et 0,  $\lambda = 0.3$  est le plus proche que l'IC et le test de Wald l'accepte.

## 5. Test de rapport de vraisemblance

```
## [1] "lambda= 1"
## [1] "TRV: 11.6612671670046"
## [1] "p_value: 0.000638148590272717"
## [1] "conserve H_0? FALSE"
## [1] "lambda= 0.5"
## [1] "TRV: 0.466380664196947"
## [1] "p_value: 0.494656961439759"
## [1] "conserve H_0? TRUE"
## [1] "lambda= 0.3"
## [1] "TRV: 0.228985473733189"
## [1] "p_value: 0.632277106839235"
## [1] "conserve H_0? TRUE"
## [1] "lambda= 1e-06"
## [1] "TRV: 5.14845895351846"
## [1] "p_value: 0.0232670132748466"
## [1] "conserve H_0? FALSE"
```

Par l'équation (20),  $TRV$  suit une loi  $\chi^2(1)$ , donc de même façon on calcule les  $TRV$  observés et les p-valeurs. De même façon d'analyser les résultats calculés, les conclusions sont mêmes que ce qui données par le test Wald dans question précédente.

## 6. Vérification par fonction "powerTransform"

Etant donné que l'on a toujours des problèmes sur l'installation du package "car", on l'exécute sur compilateur en ligne et voici dessous les résultats obtenus.

On peut voir que l'estimateur de la puissance transformation appliquée sur  $Y$  est la même valeur que l'on a obtenu par maximisation la vraisemblance  $L_{max}$  calculé par *nlm* dans la question 3. Puis l'intervalle de confiance  $[0.0452, 0.7183]$  est identique que l'on calcule dans question 4 au niveau asymptotique  $\alpha = 0.05$ . Comme on a montré dans question 5,  $TRV \sim \chi^2(1)$ , pour  $\lambda = 1$  et  $\lambda = 0$ , notre  $TRV$  observés et les p-valeurs sont les mêmes que les résultats donnés par fonction *powerTransform*.

## 3 Cas pratique

### 1. Modèle regression linéaire multiple

On définit le modèle linéaire multiple (M1)  $y = \mu + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_3 + \sigma \varepsilon$ ,  $\varepsilon \sim \mathcal{N}(0, I_n)$  i.i.d.

```
res <- powerTransform(Y~X, family="bcPower")  
summary(res)
```



**Run (Ctrl-Enter)**

Any scripts or data that you put into this service are public.

```
Loading required package: carData  
bcPower Transformation to Normality  
  Est Power Rounded Pwr Wald Lwr Bnd Wald Up Bnd  
Y1    0.3817      0.5    0.0452    0.7183  
  
Likelihood ratio test that transformation parameter is equal to 0  
(log transformation)  
              LRT df      pval  
LR test, lambda = (0) 5.148486  1 0.023267  
  
Likelihood ratio test that no transformation is needed  
              LRT df      pval  
LR test, lambda = (1) 11.66127  1 0.00063815
```

FIGURE 1 – powerTransform

2.

3.

## Conclusion